

## 作业感受

### (1) 搭建过程:

1. 环境配置: 我在 Windows 上安装了 WSL2 和 Ubuntu 但是由于网络问题在线命令安装并未成功 我选择下载离线包导入安装
  2. python: Ubuntu 禁止了 pip 的全局装包 在 ai 的建议下 我选择了虚拟环境启动
  3. SGLang: 按要求安装 0.5.14 但是其 pytorch 依赖 CUDA13 而我的驱动仅支持 12.9 导致报错 我强制更新过 CDUA12 的 pytorch 更换不同的源 均未成功 不得已选择升级显卡驱动 换用 SGLang0.5.20
  4. 启动模型: 我向 ai 要来了提示词 启动了模型 并完成了推理
  5. 从 Mooncake trace 采集了 20 条请求 记录了结果
- 过程中我大量借助了 ai 让它帮我分析问题寻找解决办法 我进行选择 and 尝试

### (2) 最困难的部分:

大概是环境的配置

我的笔记本显卡是 RTX5060 驱动为(CUDA12.9) 对于任务中 SGLang 的无法运行 我尝试许多办法 最后选择更新更高的驱动(CUDA13)并换用新版 SGLang

尝试: 1.降级 Pytorch 但是 CUDA13 不支持

2. 选择降到 CUDA12 但是官网网站无法打开

3. 提升 SGLang 版本 成功跑通

### (3) 启发与感悟

从 0 到 1 的科研 要有方向导向, 理论开拓, 实际构建, 工程落地等的共同作用

科研不是一蹴而就的 我觉得科研需要极大的耐心 更多时间是在失败上面度过的

我今天光让这个模型跑起来都花了快 3 个小时 中间各种错误不断 不止一次的从头再来

不要害怕失败 坚定方向 调整自己